Model Merging 项目报告

241880227 秦乐淇 邮箱: 241880227@smail.nju.edu.cn

实验环境
GPU : NVIDIA RTX 4090 (24GB)
Python : 3.10.12
CUDA : 12.1
PyTorch : 2.1.2 + cu121
Transformers : 4.46.0
Hugging Face Hub : 0.24.0
MergeKit : 0.1.4
GitHub 仓库：767-767/model-merging-project: Machine Learning course project on model merging: SLERP, TIES, Task Arithmetic merging experiments and EMR-Merging reproduction.

Level 1

模型选择
基座模型: mistralai/Mistral-7B-v0.1
数学专家: meta-math/MetaMath-Mistral-7B
代码专家: beowolx/CodeNinja-1.0-OpenChat-7B

合并方法
1. SLERP ：在数学专家和代码专家的权重之间进行球面线性插值。参数 t 控制插值比例，t=0 时为数学专家，t=1 时为代码专家，本实验测试了 t=0.25, 0.5, 0.75 三个值。合并后的模型缺少 chat_template，初始实验中通过复制代码专家 tokenizer_config.json 临时解决 chat_template 缺失问题；后续统一采用 mergekit-tokensurgeon 对词表进行对齐，并重新完成所有实验。
2. TIES-Merging：由于三个模型词表大小不同(基座 32000, 数学专家 32001, 代码专家 32002)，TIES 和 Task Arithmetic 需要计算专家权重-基座权重，embedding 层和 LM head 层无法直接对齐。于是使用 mergekit-tokensurgeon，以代码专家的词表为模板，将基座模型和数学专家的词表统一为 32002 之后再进行合并。本实验设置 density=0.3，normalize=true，代码专家和数学专家的权重均为 0.5。
3. Task Arithmetic：同样先使用 mergekit-tokensurgeon 将基座模型和数学专家的词表统一为 32002 后再进行合并。本实验设置数学专家和代码专家的权重均为 0.5。

评估基准

Benchmark		测试内容	样本数
数学	GSM8K(Grade School Math 8K)	小学数学应用题	1319
	AGIEval SAT Math	SAT 数学单选题(四选一)	220
代码	OpenAI HumanEval	人工设计的 Python 函数生成与单元测试验证	164
	MBPP(Mostly Basic Python Problem)	入门级 Python 编程问题	500

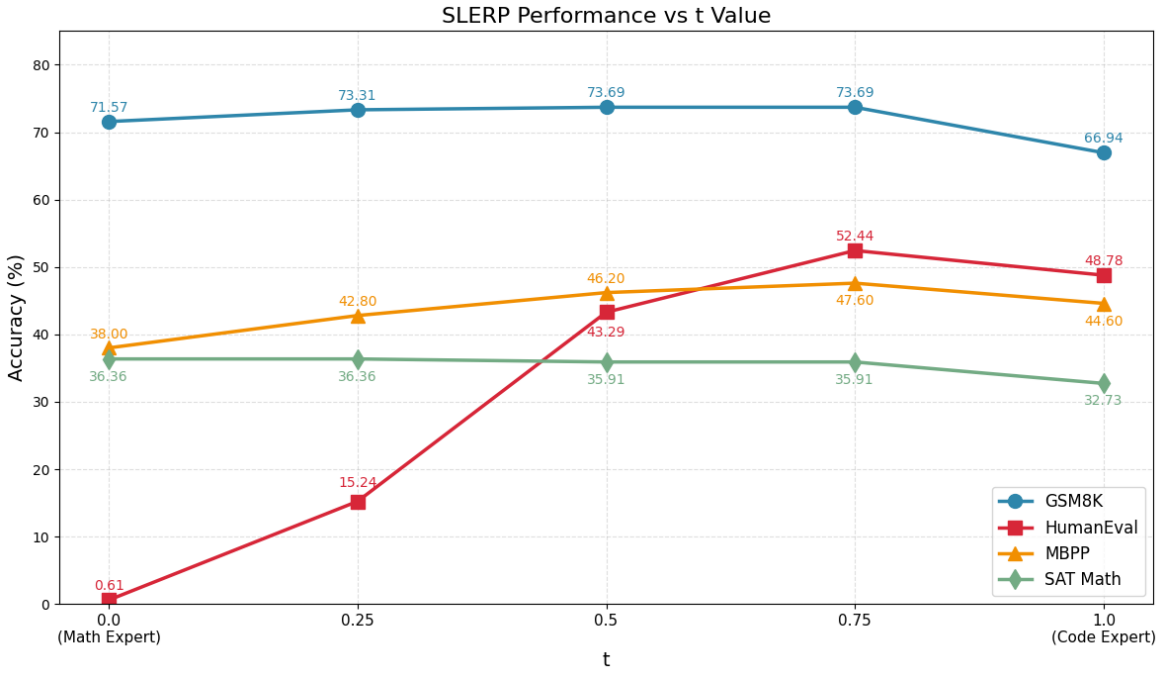
注：所有评估均遵循各基准的官方标准协议（GSM8K: 5-shot, HumanEval: 0-shot, MBPP: 3-shot, SAT Math: 0-shot)

实验结果

模型	数学		代码	
	GSM8K	SAT Math	HumanEval	MBPP
基座模型	38.21%	34.09%	1.22%	38.0%
数学专家	71.57%	36.36%	0.61%	38.0%
代码专家	66.94%	32.73%	48.78%	44.6%
SLERP 合并(t=0.25)	73.31%	36.36%	15.24%	42.8%
SLERP 合并(t=0.5)	73.69%	35.91%	43.29%	46.2%
SLERP 合并(t=0.75)	73.69%	35.91%	52.44%	47.6%
TIES 合并(density=0.3)	75.36%	32.27%	50.61%	46.0%
Task Arithmetic	73.39%	35.45%	43.29%	46.0%

结果分析

1. SLERP 的 t 值对合并性能的影响



- **数学能力对 t 值较为不敏感**

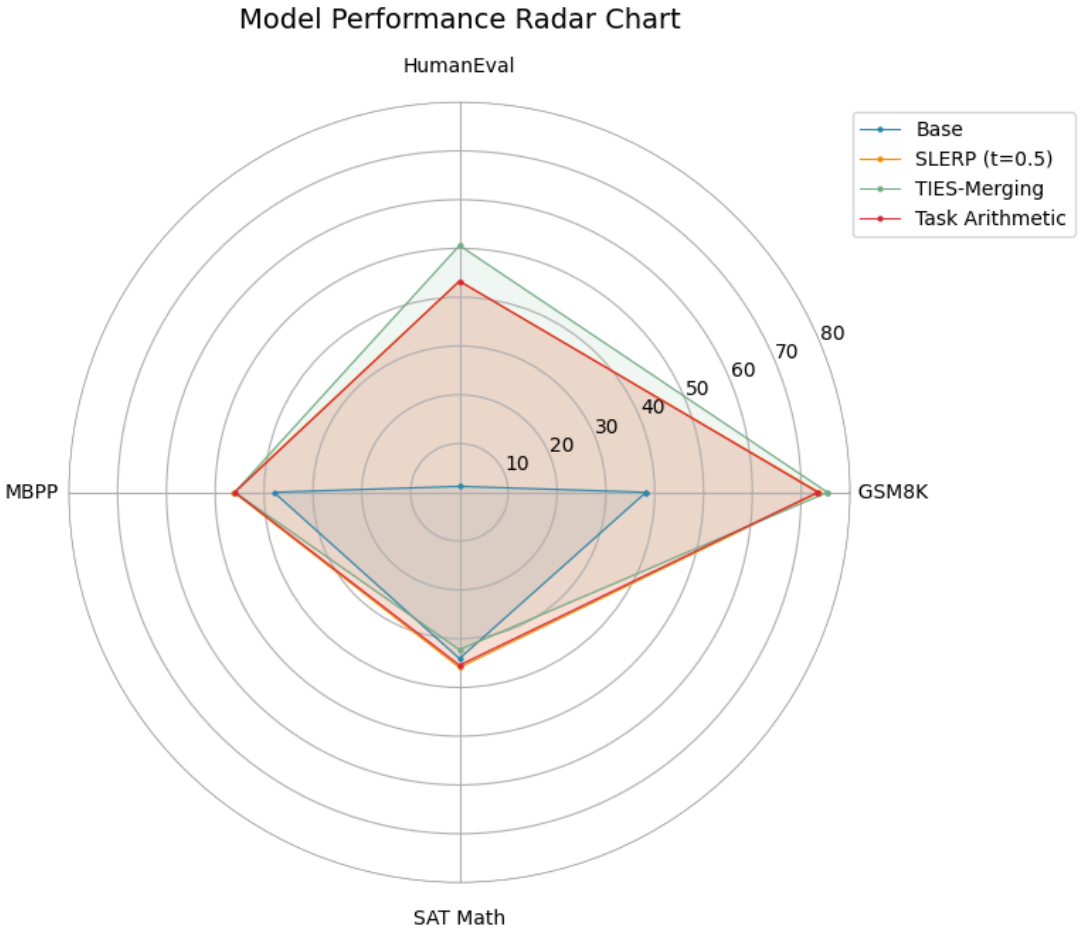
代码专家也具备较强的数学推理能力，与数学专家相差较小，这可能是由于代码生成任务涉及的逻辑推理等依赖于数学基础。所以在 t 值变化过程中，合并模型的数学能力整体非常稳定。另外，合并模型在 GSM8K 数据集上均明显强于基座模型(38.21%)，但在 SAT Math 数据集上与基座模型(34.09%)相差不大，这是因为 SAT Math 采用选择题形式，评估时根据各选项的似然选择最终答案，因此相比 GSM8K 开放式数值生成任务，对完整推理过程的依赖程度较低，所以数学专家与基座模型本身区分度就不高，合并模型在 SAT Math 上的准确率与基座也相差不大。

- **代码能力对 t 值较为敏感**

由于数学专家与代码专家的代码能力存在一定差异，所以合并模型的代码能力对于 t 的变化较为敏感，但在所选取的两个数据集上存在差异。HumanEval 要求模型从头生成完整的函数体，评估依赖于代码能否通过单元测试，对语法正确性和逻辑完备性的要求都非常高，数学模型(0.61%)与基座模型(1.22%)几乎不存在这样的代码能力，因此，随着 t 的增大，代码专家的权重

更大，合并模型在 HumanEval 上的准确率提升。而 MBPP 为入门级编程问题，且评估时采用的 3-shot 设置使模型可以从示例中学习输出格式，这导致基座模型(38.00%)和数学专家在这个数据集上的准确率并不低，与代码专家的差异较小，但总体来说随着 t 的增大，合并模型在 MBPP 数据集上的准确率还是有所提升，且 t=0.5 和 t=0.75 时一度超越了代码专家。
结合四个数据集来看，t=0.75 时，合并模型在两个代码数据集上的准确率已经超过了代码专家，并且在两个数学的数据集上准确率也非常高(GSM8K 上超过数学专家，SAT Math 上仅与数学专家相差不到 0.5%)，说明适度的模型融合能在一定程度上兼顾各模型的能力，并可能在部分任务上达到比单一专家更好的效果。

2. 合并模型与基座模型能力对比



除了 TIES 合并后的模型在 SAT Math 上的准确率略低于基座，SLERP 和 Task Arithmetic 合并模型的数学代码能力都相较基座有了明显的提升，TIES 合并模型在其他三个数据集上的准确率也较基座模型有明显提升，SAT Math 这一基准本身区分度有限。
比较 SLERP 和 Task Arithmetic，两者的合并模型在 4 个数据集上的准确率均几乎一样，可能是由于两个专家都由同一个基座模型微调而来，参数空间距离较近，所以 SLERP 球面插值与 Task Arithmetic 基于任务向量的加权结果比较相似。
比较 Task Arithmetic 和 TIES-Merging，TIES 合并模型在 HumanEval 和 GSM8K 上的准确率高于 Task Arithmetic，这可能是因为 TIES 的 Trim 和 Elect Sign 两个步骤，使得代码专家和数学专家在某些方向上的冲突得到了比较合理的解决，避免直接相加可能导致的某些信号的抵消；由于 SAT Math 对基础知识的覆盖要求较高，可能丢失了一些对 GSM8K 影响较小、但与 SAT Math 相关的参数，导致 TIES 合并模型在 SAT Math 上的准确率下降。

实验过程中遇到的问题与解决方法

- **SLERP 模版缺失问题**:

进行 SLERP 合并时，最初 HumanEval 评估报错缺少 chat_template，通过复制代码专家的 tokenizer_config.json，可以成功使用 apply_chat_template 并跑通测试。但是后来在尝试 TIES 合并时发现，这样直接复制其实无法像使用 tokensurgeon 之后再合并那样实现无损融合，可能由于 SLERP 底层的矩阵插值要求维度一致，合并框架将代码专家截断为 32001 维。由于测试集数据中未涉及缺失的权重，所以能够跑通，但这种方式存在风险。后来使用 surgeon 后的数学专家再与代码专家合并重新测试，测试结果与上一版差别较小，surgeon 后的基座模型与数学专家在所选 4 个数据集上的准确率均与未进行 surgeon 的基座和数学专家相等。

- **词表不一致问题：**

一开始未对数学专家和代码专家进行处理，直接使用 TIES-Merging 和 Task Arithmetic 进行合并，在 HumanEval 上评估时持续报错，通过排查发现是因为三个模型的词表大小各不相同，基座模型为 32000，数学专家为 32001，代码专家为 32002，而 TIES 和 Task Arithmetic 需要计算专家权重-基座权重，需要参与计算的模型词表大小相同，否则张量维度无法对齐，推理时访问不存在的 token 索引触发了 CUDA 错误。为了解决该问题，使用 mergekit-tokensurgeon 工具，以代码专家的词表为模板，将基座模型和数学专家的词表统一扩展至 32002，合并代码专家与扩展后的数学专家，即可正常在 HumanEval 等数据集测试。

Level 2

选取论文：EMR-MERGING: Tuning-Free High-Performance Model Merging. (NeurIPS 2024)
官方仓库：https://github.com/harveyhuang18/EMR_Merging

完成内容

1. Merging vision models：跑通官方 ViT 代码，在 ViT-B/32, ViT-B/16 和 ViT-L-14 三种架构上，合并全部 8 个任务后，在 MNIST 和 SVHN 数据集上验证合并模型性能，结果与论文 Table 2, 3 和 11 基本一致。
2. Merging language models：跑通 RoBERTa 和 GPT-2 的 GLUE 实验，分别在 8 个和 7 个 GLUE 任务上验证 EMR-Merging 的性能，结果与论文 Table 5 和 6 基本一致。

核心代码修改

merge_vit/ :

- src/main_emr_merging.py: 移除了原代码中对 ViT-B-32 的硬编码，通过 argparse 引入 --model 参数，支持通过命令行参数灵活切换 ViT-B-32, ViT-B-16, ViT-L-14 等不同架构的模型。添加 --train-dataset 参数对 eval_datasets 的动态覆盖，便于验证指定的数据集。
- task_vectors.py: 将 torch.load 替换为兼容当前 PyTorch 版本的加载方式。

merge_lm/ :

- merge_roberta_glue.py: 修复硬编码的数据集加载路径，替换 tokenizer 加载方式。
- merge_gpt_glue.py: 修复--ckpt_path 默认路径以适配本地权重目录结构；替换 tokenizer 加载方式；替换适配的基座模型加载路径、微调模型加载路径和数据集加载方式。

复现结果

ViT :

模型架构	MNIST		SVHN	
	本实验准确率	论文报告值	本实验准确率	论文报告值
ViT-B-32 (Table 2)	99.58%	99.6%	96.8577%	96.9%
ViT-B-16 (Table 11)	99.62%	99.6%	97.6337%	97.6%
ViT-L-14 (Table 3)	99.69%	99.7%	97.9448%	97.9%

RoBERTa on GLUE (Table 5 EMR-Merging 行):

	CoLA	SST2	MRPC	STSB	QQP	MNLI	QNLI	RTE
实验值	0.3996	0.9335	0.8627	0.8277	0.8972	0.8545	0.8957	0.7437
论文报告值	0.3996	0.9335	0.8627	0.8277	0.8972	0.8545	0.8957	0.7437

注：各任务的评估指标遵循 GLUE 基准官方标准。CoLA 使用 Matthews 相关系数，STS-B 报告 Pearson 和 Spearman 相关系数的平均值，其余任务报告 Accuracy.

GPT2 on GLUE (Table 6 EMR-Merging 行):

	CoLA	MNLI	MRPC	QNLI	QQP	RTE	SST2
实验准确率(%)	72.7709	81.0822	79.1667	84.8435	88.1128	66.4260	90.2523
论文报告值(%)	72.8	81.1	79.2	84.8	88.1	66.5	90.3

实验过程中遇到的问题与解决方法

主要是各种数据集下载、错误路径以及版本兼容问题，分别通过更换可用的数据源、修改硬编码路径、调整版本依赖和加载方式等解决。

局限：由于适配器权重获取困难，PEFT 实验(Table 7)未完成；由于设备资源的限制，30 个视觉任务的实验(Table 4)和 BEiT-3 实验(Table 8)未完成。

总结与思考

1. 简单的权重叠加或插值能够在一定程度上实现模型跨领域的能力融合，但是多任务向量之间往往存在参数方向上的冲突，EMR-Merging 在面对多路不同任务的融合时，能够有效缓解传统合并方法中的性能相互抵消，从而在有限的模型容量中实现大量不同方向任务能力的共存。
2. 在探索模型合并时，一些算法层面的理论(如球面插值或任务向量求和)建立在各专家模型参数空间完全同构的理想假设的基础上。然而在实际应用中，例如 level1 中的数学和代码专家，模型在微调阶段为了适应特定任务所引发的物理维度分化，例如词表大小不一样，会直接打破参数空间的一致性。这种物理架构层面的微小差异，不仅可能会导致显性的张量运算崩溃，更可能在框架后台引发隐式的权重截断等问题，需要建立标准化的底层架构对齐范式，或开发不受物理架构限制的合并算法，来保证合并的安全以及模型能力的稳固。

文件结构说明

Level 1 : configs/ : 合并配置文件

results/ : 完整评估结果

Level 2 : (数据集、各权重文件夹均未提交)

```
EMR_Merging/
├── merge_vit/                          # ViT实验
│   ├── src/
│   │   ├── home/
│   │   │   └── emr-merging/
│   │   │       ├── data/               # 数据集
│   │   │       ├── checkpoints/        # 各架构模型权重 (ViT-B-32、B-16、L-14)
│   │   │       └── logs/               # 测试结果日志
│   │   ├── main_emr_merging.py
│   │   ├── task_vectors.py
│   │   └── ...
│   └── ...
│
└── merge_lm/                           # NLP实验
    ├── merge_roberta_glue.py           # RoBERTa GLUE 实验入口
    ├── merge_gpt_glue.py               # GPT-2 GLUE 实验入口
    ├── ckpts/                          # 模型权重目录 (RoBERTa和GPT-2)
    ├── save_merge_logs/                # 实验结果日志
    │   └── emr-merging/
    │       ├── gpt2/                   # GPT-2实验日志
    │       └── roberta-base/           # RoBERTa实验日志
    └── ...
```